

Vietnamese Hotel Review Sentiment Analysis using Machine Learning and Deep Learning

Quốc Khánh, Phúc Bình, Tấn Phát

HUTECH – Trường Đại học Công nghệ TP.HCM, Việt Nam

Tóm tắt

Phân tích cảm xúc (sentiment analysis) là một trong những bài toán quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên, đặc biệt trong ngành du lịch – khách sạn, nơi các đánh giá của khách hàng đóng vai trò then chốt trong việc nâng cao chất lượng dịch vụ và hỗ trợ ra quyết định kinh doanh. Nghiên cứu này tập trung vào việc xây dựng và đánh giá các mô hình phân tích cảm xúc cho dữ liệu đánh giá khách sạn bằng tiếng Việt.

Dữ liệu được thu thập từ trang web Agoda.com, sau đó được tiền xử lý. Hai hướng tiếp cận chính được áp dụng bao gồm: các mô hình học máy truyền thống như Logistic Regression và Support Vector Machine kết hợp với biểu diễn đặc trưng TF-IDF, và mô hình học sâu dựa trên kiến trúc Transformer, cụ thể là DistilBERT. Các mô hình được huấn luyện và đánh giá dựa trên các chỉ số phổ biến như Accuracy, Precision, Recall và F1-score.

Kết quả thực nghiệm cho thấy mô hình DistilBERT đạt hiệu suất vượt trội với chỉ số **F1-Macro** vượt trội (**0.7974**) trong việc nắm bắt ngữ nghĩa và ngữ cảnh của tiếng Việt. Nghiên cứu này khẳng định tiềm năng của các mô hình ngôn ngữ tiền huấn luyện trong bài toán phân tích cảm xúc tiếng Việt, đồng thời đề xuất các hướng phát triển trong tương lai như mở rộng tập dữ liệu và tối ưu hóa quá trình huấn luyện nhằm nâng cao độ tổng quát của mô hình.

1. Giới thiệu

Sự bùng nổ dữ liệu văn bản trực tuyến trong những năm gần đây đã thúc đẩy sự phát triển mạnh mẽ của xử lý ngôn ngữ tự nhiên (NLP), trong đó phân tích cảm xúc trở thành một hướng nghiên cứu quan trọng. Kỹ thuật này giúp nhận diện và phân loại thái độ, quan điểm của người dùng từ văn bản, mang lại thông tin giá trị cho các lĩnh vực như thương mại điện tử, mạng xã hội và dịch vụ.

Trong ngành khách sạn, đánh giá trực tuyến của khách hàng ảnh hưởng trực tiếp đến hình ảnh thương hiệu và quyết định lựa chọn của khách tiềm năng. Phân tích cảm xúc từ các đánh giá này hỗ trợ doanh nghiệp nắm bắt mức độ hài lòng, phát hiện vấn đề và cải thiện dịch vụ, qua đó nâng cao năng lực cạnh tranh.

Tuy nhiên, việc áp dụng cho tiếng Việt gặp nhiều thách thức do ngữ pháp linh hoạt, giàu sắc thái biểu cảm, thường dùng từ lóng, viết tắt và phụ thuộc mạnh vào ngữ cảnh. Những đặc điểm này khiến việc xử lý ngôn ngữ trở nên phức tạp hơn so với tiếng Anh.

Xuất phát từ thực tế đó, nghiên cứu này tập trung xây dựng và đánh giá các mô hình phân tích cảm xúc trên dữ liệu đánh giá khách sạn tiếng Việt, so sánh giữa phương pháp học máy truyền thống và học sâu dựa trên Transformer.

2. Tổng quan nghiên cứu

Các nghiên cứu về xử lý ngôn ngữ tự nhiên cho tiếng Việt đã chuyển dịch mạnh mẽ từ các phương pháp truyền thống dựa trên tần suất từ sang các kiến trúc học sâu hiện đại. Các phương pháp truyền thống như SVM và Logistic Regression được ưa chuộng nhờ tính đơn giản, hiệu quả và chi phí tính toán thấp. Tuy nhiên, nhược điểm của chúng là phụ thuộc vào đặc trưng TF-IDF, dẫn đến việc thiếu khả năng hiểu ngữ cảnh sâu và nhạy cảm với các biến thể ngôn ngữ như từ lóng hay cấu trúc câu phức tạp.

Ngược lại, các phương pháp học sâu hiện đại, tiêu biểu là DistilBERT, mang lại ưu thế vượt trội nhờ khả năng nắm bắt ngữ cảnh hai chiều thông qua kiến trúc Transformer.

3. Phương pháp nghiên cứu

3.1 Mô tả tập dữ liệu

Tập dữ liệu đánh giá khách sạn từ trang web Agoda.com được sử dụng trong nghiên cứu này bao gồm nhiều đặc trưng đa dạng như: mã định danh khách sạn và mã đánh giá, điểm xếp hạng, tiêu đề nhận xét, nội dung nhận xét chi tiết, ngày đánh giá, thời gian nhận phòng, tên người đánh giá, quốc gia, loại nhóm khách, thời gian lưu trú, loại phòng, nguồn dữ liệu và ngôn ngữ gốc của bài đánh giá.

Trong nghiên cứu này, nhóm chỉ giữ lại phần văn bản đánh giá và nhãn cảm xúc (*label*) để phục vụ bài toán phân loại cảm xúc. Nhãn được gán thủ công dựa trên nội dung ngữ nghĩa của từng đánh giá.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	hotel_id	review_id	rating	title	comment	review_date	check_in	reviewer_name	country	group_type	stay_length	room_type			
6	443623	1010856905	8.8	Tiền làm nơi nghỉ	Mình check out phòng trưa nhưng	2025-08-18T04:2025-08-13T00:00	Quyên	Việt Nam	Cặp đôi			1 Phòng Standard giường đôi			
8	443623	1071805569	6.8	Đi công tác	Phòng ở vị trí thuận tiện, ngày trú	2026-02-01T10:2026-01-27T00:00	Loi	Việt Nam	Đi công tác			1 Phòng Loại Sang có Giường Lớn - Cầm Hút Thuốc			
15	443623	1052191992	7.6	Khách sạn	Tuy phòng k đẹp và đồ cũ, nhà vs	2025-11-17T09:2025-11-06T00:00	Nguyễn	Việt Nam	Cặp đôi			2 Phòng Standard giường đôi			
17				Mình đặt trên Agoda là 190k/dêm	Về vị trí: gần Quảng trường, công										
				Về nhân viên: vui vẻ, nhiệt tình h	Về phòng: vừa vặn 1-2 người (24										
	443623	808554073	9.2	Nền ghé	Mình đánh giá 9/10, nếu có dịp t	2024-05-20T05:2024-05-16T00:00	Nhung	Việt Nam	Du lịch một mình			2 Phòng Standard giường đôi			
19	443623	1003727927	8.8	Khách sạn giá rẻ	Nếu chỉ xét tiền thì ổn với giá. N	2025-11-19T01:2025-07-26T00:00	Thiên	Việt Nam	Cặp đôi			1 Phòng Standard giường đôi			
21	443623	902997170	8.4	Phòng budget	(-) phòng nhỏ hơn tưởng tượng, (+							2 Phòng Standard giường đôi			
27	443623	1002434447	8.4	Tuyệt vời	(+) phòng gia đình có cửa sổ nên	2024-12-13T03:2024-12-07T00:00	Tuyết	Việt Nam	Cặp đôi			2 Phòng Standard giường đôi			
				Phòng phù hợp với giá tiền ai G	2025-08-02T03:2025-07-29T00:00	Manh	Việt Nam	Cặp đôi				2 Phòng Standard giường đôi			
42				Điểm cộng:	- Ở trung tâm thành phố										
				- Giá cả phải chăng	- Nhân viên phục vụ nhiệt tình										
				Điểm trừ:	- KS cũ nên nội thất xuống cấp										
	149036	1064130755	9.2	Giá cả tốt, KS h	- Đồ ăn sáng khá là ít lựa chọn	2026-01-04T03:2025-02-01T00:00	Minh	Việt Nam	Gia đình có em i			1 Phòng Deluxe Có Giường Cờ King			

Hình 1: Các cột đặc trưng trong tập dữ liệu ban đầu

3.2 Tiền xử lý dữ liệu

Dữ liệu được chuẩn hóa bằng cách chuyển toàn bộ văn bản về chữ thường, loại bỏ URL, ký tự đặc biệt và chữ số, đồng thời chuẩn hóa một số dạng viết tắt thường gặp trong tiếng Việt. Bước tách từ cũng được áp dụng nhằm đảm bảo các cụm từ có ý nghĩa được giữ nguyên trong quá trình biểu diễn đặc trưng.

Đối với các mô hình học máy truyền thống, nhóm xây dựng danh sách gồm 69 từ dừng tiếng Việt và loại bỏ các từ này để giảm nhiễu khi sử dụng TF-IDF. Ngược lại, với mô hình DistilBERT, dữ liệu được chuẩn hóa Unicode (NFC), loại bỏ @mention và dấu gạch dưới, nhưng không loại bỏ stopwords để bảo toàn tối đa ngữ cảnh ngôn ngữ cho mô hình.

Sau quá trình làm sạch và tiền xử lý dữ liệu, tập dữ liệu còn lại **11.476 mẫu**. Đây là bộ dữ liệu đầu vào chính được sử dụng cho toàn bộ quá trình huấn luyện, tinh chỉnh và đánh giá mô hình.


3.3 Phân tích mất cân bằng nhãn và chiến lược chia tập dữ liệu

3.3.1 Phân tích vấn đề mất cân bằng nhãn

Tập dữ liệu đánh giá khách sạn thu thập từ Agoda sau bước làm sạch còn lại 11.476 mẫu, với phân bố theo ba nhãn cảm xúc như sau: nhãn positive chiếm 8.067 mẫu (70,3%), nhãn negative chiếm 2.769 mẫu (24,1%), và nhãn neutral chỉ có 640 mẫu (5,6%). Sự chênh lệch này phản ánh

đặc điểm tự nhiên của dữ liệu đánh giá trực tuyến, khi người dùng có xu hướng để lại nhiều nhận xét tích cực hơn, trong khi các nhận xét trung lập thường ngắn gọn và ít được đăng tải hơn.

Tình trạng mất cân bằng nhãn ở mức độ rõ rệt đặt ra thách thức lớn cho quá trình huấn luyện mô hình. Nếu không có biện pháp xử lý phù hợp, mô hình sẽ có xu hướng thiên lệch về lớp chiếm đa số, cụ thể là lớp positive, và không học được đầy đủ đặc trưng của các lớp thiểu số, đặc biệt là lớp neutral. Trong trường hợp cực đoan, mô hình có thể đạt giá trị Accuracy tương đối cao chỉ bằng cách dự đoán phần lớn mẫu thuộc lớp positive, nhưng lại thất bại trong nhiệm vụ phân loại thực chất. Vì lý do đó, nghiên cứu này lựa chọn F1-Macro làm chỉ số đánh giá chính thay vì chỉ dựa vào Accuracy.



Hình 2: Phân bố số lượng và tỷ lệ các nhãn cảm xúc trong tập dữ liệu sau tiền xử lý

3.3.2 Chiến lược xử lý mất cân bằng

Nghiên cứu sử dụng hai cách xử lý mất cân bằng dữ liệu khác nhau cho hai nhóm mô hình. Với SVM và Logistic Regression, sau khi biểu diễn văn bản bằng TF-IDF, kỹ thuật SMOTE được áp dụng trên tập train để tạo thêm mẫu cho lớp thiểu số, giúp cân bằng dữ liệu từ 9.161 lên 19.350 mẫu; đồng thời kết hợp `class_weight="balanced"` để giảm thiên lệch nhãn. SMOTE chỉ được dùng sau bước vector hóa TF-IDF và không áp dụng cho validation hay test nhằm tránh data leakage.


Với DistilBERT, do không thể áp dụng SMOTE trực tiếp trong không gian biểu diễn ngữ nghĩa, nghiên cứu thay thế bằng hai kỹ thuật: class weights tính theo nguyên tắc balanced rồi làm mượt bằng căn bậc hai để tránh overfitting, và label smoothing = 0,05 để giảm sự tự tin quá mức của mô hình. Các trọng số lớp sau làm mượt được đưa vào hàm mất mát CrossEntropyLoss thông qua WeightedLossTrainer, giúp mô hình học cân bằng hơn, đặc biệt trên các lớp thiểu số.

3.3.3 Chia tập dữ liệu với Stratified Split

Tập dữ liệu được chia thành ba tập con theo tỷ lệ **80–10–10**, tương ứng với tập huấn luyện (*train*) gồm 9.161 mẫu, tập kiểm tra nội bộ (*validation*) gồm 1.146 mẫu, và tập kiểm tra cuối cùng (*test*) gồm 1.146 mẫu. Quá trình chia được thực hiện theo hai bước tuần tự: trước hết tách 10% dữ liệu làm tập test, sau đó từ phần dữ liệu còn lại tiếp tục tách khoảng 11,11% để tạo tập validation,

phần còn lại được sử dụng làm tập train.

Điều kiện then chốt trong cả hai bước chia là sử dụng **Stratified Split**, tức là bảo toàn tỷ lệ phân bố nhãn trong từng tập con sao cho gần tương đương với phân bố nhãn của toàn bộ tập dữ liệu gốc. Sau khi chia, cả ba tập train, validation và test đều duy trì phân bố xấp xỉ: positive khoảng 70%, negative khoảng 24% và neutral khoảng 5,5%, cho thấy cơ chế stratification hoạt động chính xác. Toàn bộ quá trình chia dữ liệu sử dụng `random_state=42` nhằm đảm bảo tính tái lập (*reproducibility*) của thí nghiệm.



Hình 3: Phân bố nhãn giữa các tập

Việc sử dụng Stratified Split mang lại ba lợi ích quan trọng. Thứ nhất, nó giúp duy trì tính nhất quán thống kê giữa các tập dữ liệu, từ đó làm cho kết quả đánh giá phản ánh đúng năng lực tổng quát hóa của mô hình. Thứ hai, với lớp neutral chỉ chiếm khoảng 5,5%, nếu không thực hiện stratification thì tập validation hoặc test có thể chứa quá ít mẫu của lớp này, làm sai lệch đáng kể các chỉ số đánh giá như F1-Macro. Thứ ba, tập test được tách biệt hoàn toàn trong suốt quá trình phát triển mô hình, không được sử dụng để lựa chọn siêu tham số hay điều chỉnh kiến trúc, và chỉ được mở ra một lần duy nhất ở bước đánh giá cuối cùng nhằm đảm bảo tính khách quan của kết quả nghiên cứu.

3.4 Các thuật toán sử dụng

3.4.1 TF-IDF

TF-IDF (Term Frequency – Inverse Document Frequency) là một phương pháp biểu diễn văn bản phổ biến, giúp đo lường mức độ quan trọng của một từ trong một tài liệu so với toàn bộ tập văn bản.

$$TF(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}} \quad (1)$$

$$IDF(t) = \log \frac{N}{df(t)} \quad (2)$$

$$TF-IDF(t, d) = TF(t, d) \times IDF(t) \quad (3)$$

3.4.2 Logistic Regression

Logistic Regression là mô hình phân loại tuyến tính, trong đó đầu ra được ánh xạ thành xác suất thuộc về một lớp nhất định.

$$z = \mathbf{w}^T \mathbf{x} + b \quad (4)$$


$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (5)$$

3.4.3 Linear SVM

Linear SVM tìm kiếm một siêu phẳng tối ưu để phân tách các lớp dữ liệu trong không gian đặc trưng.

3.4.4 DistilBERT


DistilBERT là một mô hình ngôn ngữ thuộc họ Transformer, được đề xuất như một phiên bản rút gọn của BERT nhằm giảm chi phí tính toán trong khi vẫn giữ được phần lớn khả năng biểu diễn ngữ nghĩa. So với BERT-base, DistilBERT có số lượng tham số ít hơn đáng kể do giảm số tầng Transformer Encoder, từ đó giúp rút ngắn thời gian huấn luyện và suy luận, đồng thời giảm yêu cầu về tài nguyên phần cứng.



Hình 4: Kiến trúc DistilBERT

Về kiến trúc, DistilBERT kế thừa cấu trúc Transformer Encoder, bao gồm các thành phần chính

là lớp embedding, cơ chế self-attention và các tầng encoder được xếp chồng. Lớp embedding kết hợp biểu diễn từ vựng (token embedding) và thông tin vị trí (positional embedding) nhằm cung cấp cho mô hình cả ngữ nghĩa và trật tự của các token trong câu. Khác với BERT-base, DistilBERT không sử dụng token-type embedding do không áp dụng nhiệm vụ Next Sentence Prediction trong giai đoạn tiền huấn luyện.



Hình 5: Cơ chế attention của DistilBERT

Cơ chế self-attention cho phép mỗi token trong câu học được mối quan hệ ngữ nghĩa với các token khác, giúp mô hình nắm bắt các phụ thuộc xa và cấu trúc ngữ cảnh phức tạp. Đây là yếu tố quan trọng giúp DistilBERT vượt trội hơn các mô hình tuyến tính truyền thống trong các bài toán yêu cầu hiểu ngữ cảnh, chẳng hạn như phân tích cảm xúc.

4. Chỉ số đánh giá

Để đánh giá hiệu suất của các thuật toán phân loại cảm xúc, nghiên cứu sử dụng các chỉ số đo lường chuẩn sau:

4.1 Độ chính xác (Accuracy)

Đo lường tỷ lệ dự đoán đúng trên tổng số mẫu.

$$\text{Accuracy} = \frac{\text{correct classifications}}{\text{total classifications}} = \frac{TP + TN}{TP + TN + FP + FN} \quad (6)$$

4.2 F1-Macro

Đây là chỉ số đánh giá chính trong nghiên cứu này do tập dữ liệu có sự chênh lệch giữa các nhãn (mất cân bằng dữ liệu). F1-Macro tính trung bình cộng F1-Score của từng lớp (Tích cực, Tiêu cực, Trung lập) mà không phụ thuộc vào kích thước mẫu của lớp đó.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (7)$$


4.3 Ma trận nhầm lẫn (Confusion Matrix)

Công cụ này được sử dụng để quan sát chi tiết các sai sót của mô hình.

4.4 Precision và Recall

Precision là độ chính xác của dự đoán theo từng lớp, trong khi Recall phản ánh khả năng nhận diện đầy đủ các mẫu thuộc lớp đó.

5. Kết quả



Hình 6: Hình ảnh trực quan kết quả của 3 mô hình

Các thuật toán phân loại cảm xúc đã được triển khai bằng ngôn ngữ lập trình Python và kết quả được đánh giá dựa trên bộ chỉ số đo lường đã mô tả. Kết quả thực nghiệm cho thấy sự khác biệt rõ rệt về hiệu suất giữa các mô hình truyền thống và mô hình học sâu.


TF-IDF + SVM: Đạt chỉ số F1-Macro là 0.7199, cho thấy khả năng phân loại ổn định nhưng gặp khó khăn với các sắc thái ngôn ngữ phức tạp.

TF-IDF + Logistic Regression: Đạt hiệu suất nhỉnh hơn một chút với F1-Macro là 0.7290.

DistilBERT: Thể hiện hiệu suất vượt trội nhất với chỉ số F1-Macro đạt 0.7974 và Độ chính xác (Accuracy) lên tới 0.9171. Mô hình này cải thiện chỉ số F1-Macro thêm 10.8% so với các phương pháp máy học truyền thống.


Bảng 1: So sánh hiệu năng các mô hình trên tập test

Mô hình	Accuracy	Precision (macro)	Recall (macro)	F1-score (macro)
TF-IDF + SVM	0.8796	0.7077	0.7425	0.7199
TF-IDF + LR	0.8805	0.7100	0.7589	0.7290
DistilBERT	0.9171	0.7852	0.8136	0.7974




Hình 7: Ma trận nhầm lẫn cho LR

Ma trận nhầm lẫn của Logistic Regression cho thấy mô hình này có hiệu quả tổng thể nhỉnh hơn SVM một chút và cân bằng hơn giữa các lớp. Ở lớp negative, Logistic Regression dự đoán đúng 228/276 mẫu, tương ứng 83% recall, cao hơn SVM và khá gần DistilBERT. Ở lớp positive, mô hình nhận diện đúng 748/807 mẫu, tương ứng 93% recall, thấp hơn SVM một chút nhưng vẫn rất cao. Với lớp neutral, Logistic Regression dự đoán đúng 33/63 mẫu, tương ứng 52% recall, chỉ nhỉnh hơn SVM rất ít. Điều này cho thấy dù Logistic Regression đã cải thiện khả năng nhận diện lớp negative và giữ độ ổn định tổng thể tốt, nhưng vấn đề lớn nhất vẫn là chưa xử lý được tốt lớp trung lập. Nói cách khác, Logistic Regression là mô hình baseline khá mạnh, nhưng vẫn bị giới hạn bởi biểu diễn TF-IDF nên chưa khai thác tốt ý nghĩa ngữ cảnh sâu của câu



Hình 8: Ma trận nhầm lẫn cho SVM

Đối với mô hình SVM, kết quả cho thấy mô hình hoạt động khá tốt ở hai lớp cực là negative và positive, nhưng gặp khó khăn rõ rệt với lớp neutral. Cụ thể, lớp positive được nhận diện đúng 762/807 mẫu, tương ứng khoảng 94% recall, cho thấy SVM vẫn khá hiệu quả khi phân biệt các phản hồi tích cực rõ ràng. Với lớp negative, mô hình đạt 214/276 mẫu đúng, tương ứng 78% recall, ở mức chấp nhận được nhưng vẫn thấp hơn so với LR và DistilBERT. Điểm yếu lớn nhất nằm ở lớp neutral, khi chỉ dự đoán đúng 32/63 mẫu, tương ứng khoảng 51% recall. Đồng thời, có tới 37% mẫu neutral bị nhầm sang negative, cho thấy SVM khá nhạy với xu hướng kéo các phản hồi trung tính về phía tiêu cực. Điều này phản ánh hạn chế của phương pháp dựa trên TF-IDF: mô hình học tốt tần suất từ khóa, nhưng chưa hiểu đủ ngữ cảnh để tách biệt rõ lớp trung lập.



Hình 9: Ma trận nhầm lẫn cho DistilBERT

Ma trận nhầm lẫn của DistilBERT cho thấy đây là mô hình có khả năng phân loại tốt nhất trong ba mô hình, đặc biệt ở lớp positive và negative. Cụ thể, ở lớp positive, mô hình dự đoán đúng 779/807 mẫu, tương ứng 96.53% recall, tức gần như nhận diện rất tốt các phản hồi tích cực. Với lớp negative, mô hình cũng đạt 232/276 mẫu đúng, tương ứng 84.06% recall, cho thấy khả năng phát hiện phản hồi tiêu cực khá mạnh. Đáng chú ý nhất là lớp neutral đạt 40/63 mẫu đúng, tương ứng 63.49% recall. Dù đây vẫn là lớp khó nhất, kết quả này cao hơn rõ rệt so với SVM và Logistic Regression. Nhìn chung, DistilBERT không chỉ mạnh ở lớp đa số mà còn cải thiện đáng kể khả năng xử lý lớp thiểu số, chứng tỏ ưu thế của mô hình ngữ cảnh hóa sâu trong việc nắm bắt sắc thái cảm xúc tiếng Việt.

Nhìn tổng thể, cả ba ma trận nhầm lẫn đều cho thấy một xu hướng rất rõ: lớp positive là lớp dễ dự đoán nhất, lớp neutral là lớp khó nhất, còn negative nằm ở mức trung gian. Hai mô hình truyền thống là SVM và Logistic Regression cho kết quả khá tốt trên lớp positive, nhưng đều suy giảm đáng kể khi xử lý lớp neutral, đặc biệt do các mẫu trung lập dễ bị kéo về negative hoặc positive. Trong khi đó, DistilBERT vượt trội hơn rõ rệt, không chỉ vì accuracy cao hơn mà quan trọng hơn là vì mô hình xử lý cân bằng hơn giữa các lớp, đặc biệt cải thiện mạnh recall của lớp neutral từ khoảng 51–52% lên **63.49%**. Điều này cho thấy ưu thế cốt lõi của DistilBERT nằm ở khả năng hiểu ngữ cảnh và sắc thái ngôn ngữ, thay vì chỉ dựa vào tần suất từ như TF-IDF. Nếu dùng để trình bày trong báo cáo hoặc thuyết trình, bạn có thể kết luận rằng: DistilBERT là mô hình phù hợp nhất cho bài toán phân loại cảm xúc đa lớp trên dữ liệu đánh giá khách sạn tiếng Việt, đặc biệt trong bối cảnh dữ liệu mất cân bằng và lớp neutral khó nhận diện.

6. Thảo luận

Kết quả thực nghiệm khẳng định DistilBERT là mô hình tối ưu nhất cho bài toán phân loại cảm xúc đánh giá khách sạn tiếng Việt. Với kiến trúc Transformer, mô hình này vượt trội trong việc hiểu ngữ cảnh và các mối quan hệ từ vựng phức tạp, giúp cải thiện chỉ số F1-Macro thêm 10.8% so với mô hình SVM truyền thống. Khả năng này cực kỳ quan trọng đối với dữ liệu đánh giá khách sạn, vốn thường chứa nhiều từ lóng, cấu trúc câu không chính quy và các sắc thái biểu cảm đa dạng.

Ngược lại, các mô hình SVM và Logistic Regression, dù đạt độ chính xác tổng thể (Accuracy) khá tốt (trên 88%), nhưng lại bộc lộ hạn chế khi xử lý các lớp dữ liệu thiểu số. Cụ thể, các mô hình dựa trên TF-IDF này gặp khó khăn trong việc phân biệt nhãn "Trung lập", dẫn đến chỉ số F1-Macro thấp hơn đáng kể so với DistilBERT. Điều này cho thấy việc chỉ dựa vào tần suất xuất hiện của từ đơn lẻ (Bag-of-Words) là chưa đủ để nắm bắt trọn vẹn cảm xúc của khách hàng.

Mặc dù DistilBERT yêu cầu tài nguyên tính toán cao hơn và thời gian huấn luyện lâu hơn, nhưng sự đánh đổi này mang lại một hệ thống có độ tin cậy cao, cân bằng tốt giữa các nhóm cảm xúc. Đây là yếu tố then chốt để các doanh nghiệp khách sạn có thể tự động hóa quy trình phân tích phản hồi mà không bỏ sót các ý kiến đóng góp quan trọng từ khách hàng.

7. Kết luận

Nghiên cứu khẳng định DistilBERT là mô hình tối ưu nhất cho việc phân tích cảm xúc đánh giá khách sạn tiếng Việt với chỉ số F1-Macro vượt trội (**0.7974**), mang lại kết quả phân loại chính xác và có ý nghĩa hơn so với các phương pháp truyền thống. Việc ứng dụng mô hình này giúp các nhà quản lý khách sạn và logistics du lịch hiểu rõ phản hồi khách hàng để từ đó tối ưu hóa chất lượng dịch vụ và phân bổ nguồn lực hiệu quả. Việc duy trì tập dữ liệu luôn được cập nhật là nền tảng quan trọng để đảm bảo mô hình phân tích cảm xúc luôn mang lại những kết quả chính xác và có giá trị ứng dụng cao trong môi trường du lịch biến động.

8. Hướng nghiên cứu tương lai

Hướng nghiên cứu tương lai có thể tập trung vào việc phát triển các mô hình lai kết hợp giữa Transformer và các phương pháp học máy truyền thống để xử lý tốt hơn các sắc thái ngôn ngữ phức tạp như sự mỉa mai hoặc từ lóng đặc thù. Việc mở rộng sang phân tích cảm xúc dựa trên từng khía cạnh dịch vụ (Aspect-Based) sẽ cung cấp những hiểu biết chi tiết hơn, hỗ trợ đắc lực cho việc tối ưu hóa quản lý và phân bổ nguồn lực khách sạn. Cuối cùng, việc ứng dụng các kiến trúc học sâu nâng cao chuyên biệt cho tiếng Việt hoặc các phương pháp học thích ứng theo thời gian thực sẽ giúp nâng cao độ chính xác và tính linh hoạt của mô hình trong môi trường kinh doanh thực tế.

Tài liệu tham khảo

- [1] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015. DOI: [10.1038/nature14539](https://doi.org/10.1038/nature14539).
- [2] X.-S. Yang, R. S. Sherratt, N. Dey, and A. Joshi, Eds., *Proceedings of Tenth International Congress on Information and Communication Technology: ICICT 2025, London, Volume I (Lecture Notes in Networks and Systems)*. Singapore: Springer Nature Singapore, 2026, vol. 1440. DOI: [10.1007/978-981-96-9709-0](https://doi.org/10.1007/978-981-96-9709-0).
- [3] Y. Zhang, L. Gong, and Y. Wang, “An improved TF-IDF approach for text classification,” *Journal of Zhejiang University Science A*, vol. 6A, no. 1, pp. 49–55, Jan. 2005. DOI: [10.1631/jzus.2005.A49](https://doi.org/10.1631/jzus.2005.A49).
- [4] Z. Bursac, C. H. Gauss, D. K. Williams, and D. W. Hosmer, “Purposeful selection of variables in logistic regression,” *Source Code for Biology and Medicine*, vol. 3, no. 1, p. 17, Dec. 2008. DOI: [10.1186/1751-0473-3-17](https://doi.org/10.1186/1751-0473-3-17).
- [5] S. Sperandei, “Understanding logistic regression analysis,” *Biochemia Medica*, pp. 12–18, 2014. DOI: [10.11613/BM.2014.003](https://doi.org/10.11613/BM.2014.003).
- [6] C. R. Mehta and N. R. Patel, “Exact logistic regression: Theory and examples,” *Statistics in Medicine*, vol. 14, no. 19, pp. 2143–2160, Oct. 1995. DOI: [10.1002/sim.4780141908](https://doi.org/10.1002/sim.4780141908).
- [7] V. Sanh, L. Debut, J. Chaumond, and T. Wolf. “DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter.” arXiv: [1910.01108](https://arxiv.org/abs/1910.01108).
- [8] B. A. Burns et al., “Corrigendum to “Comprehensive normalization and binary classification methods for enhanced sensitivity and reproducibility in Luminex assay quantitation” [Journal of Immunological Methods 538 (2025) 113826],” *Journal of Immunological Methods*, vol. 539, p. 113 852, Apr. 2025. DOI: [10.1016/j.jim.2025.113852](https://doi.org/10.1016/j.jim.2025.113852).
- [9] S. Li and S. Jia, “The seaport traffic scheduling problem: Formulations and a column-row generation algorithm,” *Transportation Research Part B: Methodological*, vol. 128, pp. 158–184, Oct. 2019. DOI: [10.1016/j.trb.2019.08.003](https://doi.org/10.1016/j.trb.2019.08.003).
- [10] J. Liang, S. Yang, and A. Winstanley, “Invariant optimal feature selection: A distance discriminant and feature ranking based solution,” *Pattern Recognition*, vol. 41, no. 5, pp. 1429–1439, May 2008. DOI: [10.1016/j.patcog.2007.10.018](https://doi.org/10.1016/j.patcog.2007.10.018).
- [11] D. Kim, Y. Song, S. Kwon, H. Kim, J. D. Yoo, and H. K. Kim. “UAVCAN Dataset Description.” arXiv: [2212.09268](https://arxiv.org/abs/2212.09268).
- [12] D. Fogg, “Celebrating Organometallics at 35 Years, and the Advancement of Learning at 400+,” *Organometallics*, vol. 35, no. 24, pp. 4003–4003, Dec. 2016. DOI: [10.1021/acs.organomet.6b00917](https://doi.org/10.1021/acs.organomet.6b00917).