

Vietnamese Hotel Review Sentiment Analysis using Machine Learning and Deep Learning

Quốc Khánh Phúc Bình Tấn Phát

HUTECH – Trường Đại học Công nghệ TP.HCM

Nội dung trình bày

- 1 Giới thiệu
- 2 Tổng quan nghiên cứu
- 3 Phương pháp nghiên cứu
- 4 Chỉ số đánh giá
- 5 Kết luận
- 6 Hướng nghiên cứu tương lai

Tóm tắt nghiên cứu

- Phân tích cảm xúc là một trong những bài toán quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên, đặc biệt trong ngành du lịch – khách sạn.
- Nghiên cứu tập trung xây dựng và đánh giá các mô hình phân tích cảm xúc cho dữ liệu đánh giá khách sạn bằng tiếng Việt.
- Hai hướng tiếp cận chính:
 - các mô hình học máy truyền thống như Logistic Regression và Support Vector Machine kết hợp với TF-IDF;
 - mô hình học sâu dựa trên kiến trúc Transformer, cụ thể là DistilBERT.
- Các mô hình được đánh giá dựa trên Accuracy, Precision, Recall và F1-score.

- Sự bùng nổ dữ liệu văn bản trực tuyến đã thúc đẩy sự phát triển mạnh mẽ của xử lý ngôn ngữ tự nhiên, trong đó phân tích cảm xúc trở thành một hướng nghiên cứu quan trọng.
- Trong ngành khách sạn, đánh giá trực tuyến của khách hàng ảnh hưởng trực tiếp đến hình ảnh thương hiệu và quyết định lựa chọn của khách tiềm năng.
- Phân tích cảm xúc từ các đánh giá này hỗ trợ doanh nghiệp nắm bắt mức độ hài lòng, phát hiện vấn đề và cải thiện dịch vụ.
- Tuy nhiên, việc áp dụng cho tiếng Việt gặp nhiều thách thức do ngữ pháp linh hoạt, giàu sắc thái biểu cảm, thường dùng từ lóng, viết tắt và phụ thuộc mạnh vào ngữ cảnh.

Tổng quan nghiên cứu

- Các nghiên cứu về xử lý ngôn ngữ tự nhiên cho tiếng Việt đã chuyển dịch mạnh mẽ từ các phương pháp truyền thống dựa trên tần suất từ sang các kiến trúc học sâu hiện đại.
- Các phương pháp truyền thống như SVM và Logistic Regression được ưa chuộng nhờ tính đơn giản, hiệu quả và chi phí tính toán thấp.
- Tuy nhiên, nhược điểm của chúng là phụ thuộc vào đặc trưng TF-IDF, dẫn đến việc thiếu khả năng hiểu ngữ cảnh sâu và nhạy cảm với các biến thể ngôn ngữ như từ lóng hay cấu trúc câu phức tạp.
- Ngược lại, các phương pháp học sâu hiện đại, tiêu biểu là DistilBERT, mang lại ưu thế vượt trội nhờ khả năng nắm bắt ngữ cảnh hai chiều thông qua kiến trúc Transformer.

Mô tả tập dữ liệu

Tập dữ liệu đánh giá khách sạn từ Agoda bao gồm nhiều đặc trưng:

- mã định danh khách sạn và mã đánh giá,
- điểm xếp hạng,
- tiêu đề nhận xét,
- nội dung nhận xét chi tiết,
- ngày đánh giá,
- thời gian nhận phòng,
- tên người đánh giá,
- quốc gia,
- loại nhóm khách,
- thời gian lưu trú,
- loại phòng,



Minh họa dữ liệu đánh giá Agoda

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O
1	hotel_id	review_id	rating	title	comment		review_date	check_in	reviewer_name	country	group_type	stay_length	room_type		
6	443623	1010856905		8.8 Tiềm năng nơi nghỉ	Mình check out phòng trưa nhưng		2025-08-18T04:	2025-08-13T00:	Quyên	Việt Nam	Cặp đôi		1 Phòng Standard giường đôi		
8	443623	1071805569		6.8 Đi công tác	Phòng ở vị trí thuận tiện, ngay tru		2026-02-01T10:	2026-01-27T00:	Lợi	Việt Nam	Đi công tác		1 Phòng Loại Sang có Giường Lớn - Cầm Hút Thuốc		
15	443623	1052191992		7.6 Khách sạn	Tuy phòng k đẹp và đồ cũ, nhà vs		2025-11-17T09:	2025-11-06T00:	Nguyễn	Việt Nam	Cặp đôi		2 Phòng Standard giường đôi		
17					Mình đặt trên Agoda là 190k/đêm Về vị trí: gần Quảng trường, công Về nhân viên: vui vẻ, nhiệt tình h Về phòng: vừa vặn 1-2 người (2 k										
	443623	808554073		9.2 Nền ghé	Mình đánh giá 8/10, nếu có dịp pl		2024-05-20T05:	2024-05-16T00:	Nhung	Việt Nam	Du lịch một mình		2 Phòng Standard giường đôi		
19	443623	1003727927		8.8 Khách sạn giá rẻ	Nếu chỉ xét tiền thì ổn với giá . Nh		2025-11-19T01:	2025-07-26T00:	Thiên	Việt Nam	Cặp đôi		1 Phòng Standard giường đôi		
21	443623	902997170		8.4 Phòng budget	(-) phòng nhỏ hơn tưởng tượng, (		2024-12-13T03:	2024-12-07T00:	Tuyết	Việt Nam	Cặp đôi		2 Phòng Standard giường đôi		
27	443623	1002434447		8.4 Tuyệt vời	Phòng phù hợp với giá tiền al Gă		2025-08-02T03:	2025-07-29T00:	Mạnh	Việt Nam	Cặp đôi		2 Phòng Standard giường đôi		
42					Điểm cộng: - Ở trung tâm thành phố - Giá cả phải chăng - Nhân viên phục vụ nhiệt tình Điểm trừ: - KS cũ nên nội thất xuống cấp										
	149036	1064130755		9.2 Giá cả tốt, KS h	- Đồ ăn sáng khá là ít lựa chọn về		2026-01-04T03:	2025-02-01T00:	Minh	Việt Nam	Gia đình có em l		1 Phòng Deluxe Có Giường Cỡ King		

Phân bố nhãn dữ liệu

- Dữ liệu có sự mất cân bằng rõ rệt giữa các nhãn.
- Lớp **positive** chiếm tỷ lệ lớn nhất (69.4%), áp đảo so với các lớp còn lại.
- Lớp **negative** chiếm khoảng 24.1%, ở mức trung bình.
- Lớp **neutral** chiếm tỷ lệ rất nhỏ (6.6%), là lớp thiểu số.
- Điều này cho thấy dữ liệu có xu hướng nghiêng về cảm xúc tích cực.

Phân Tích Phân Bố Nhãn — final_data.csv



Dữ liệu được chuẩn hóa bằng cách:

- chuyển về chữ thường,
- loại bỏ URL, ký tự đặc biệt và số,
- xử lý các dạng viết tắt trong tiếng Việt,
- tách từ nhằm đảm bảo các cụm từ có ý nghĩa được giữ nguyên.

Đối với từng hướng tiếp cận:

- Với mô hình học máy: xây dựng danh sách 69 stopwords tiếng Việt và loại bỏ để giảm nhiễu khi sử dụng TF-IDF.
- Với DistilBERT: chuẩn hóa Unicode (NFC), loại bỏ @mention và dấu gạch dưới, nhưng không loại bỏ stopwords nhằm bảo toàn ngữ cảnh cho mô hình.

TF-IDF là một phương pháp biểu diễn văn bản phổ biến, giúp đo lường mức độ quan trọng của một từ trong một tài liệu so với toàn bộ tập văn bản.

$$TF(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}}$$

$$IDF(t) = \log \frac{N}{df(t)}$$

$$TF-IDF(t, d) = TF(t, d) \times IDF(t)$$

Logistic Regression

Logistic Regression là mô hình phân loại tuyến tính, trong đó đầu ra được ánh xạ thành xác suất thuộc về một lớp nhất định.

$$z = w^T x + b$$

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Linear SVM

- Linear SVM tìm kiếm một siêu phẳng tối ưu để phân tách các lớp dữ liệu trong không gian đặc trưng.


DistilBERT

- DistilBERT là một mô hình ngôn ngữ thuộc họ Transformer.
- Đây là phiên bản rút gọn của BERT nhằm giảm chi phí tính toán trong khi vẫn giữ được phần lớn khả năng biểu diễn ngữ nghĩa.

Chia dữ liệu (Stratified Split)

- Dữ liệu được chia thành 3 tập:
 - Train: 9161 mẫu
 - Validation: 1146 mẫu
 - Test: 1146 mẫu
- Áp dụng phương pháp **Stratified Split** để giữ nguyên tỷ lệ nhãn giữa các tập.

Phân Bố Nhãn Sau Khi Chia Tập (Stratified)



Chỉ số đánh giá

Để đánh giá hiệu suất của các thuật toán phân loại cảm xúc, nghiên cứu sử dụng các chỉ số đo lường chuẩn sau:

- **Accuracy:** đo lường tỷ lệ dự đoán đúng trên tổng số mẫu.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

- **F1-Macro:** là chỉ số đánh giá chính trong nghiên cứu này do tập dữ liệu có sự chênh lệch giữa các nhãn.



$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

- **Confusion Matrix:** được sử dụng để quan sát chi tiết các sai sót của mô hình.
- **Precision và Recall:** phản ánh độ chính xác của dự đoán và khả năng nhận diện đầy đủ các mẫu thuộc lớp đó.

Kết quả thực nghiệm

- DistilBERT đạt hiệu suất cao nhất.
- F1-Macro: 0.7974 (cao hơn SVM và Logistic Regression).
- Accuracy: 0.9171.



PHÂN TÍCH SO SÁNH HIỆU NĂNG CÁC MÔ HÌNH PHÂN LOẠI CẢM XÚC



Bảng so sánh các mô hình

Mô hình	Accuracy	Precision-Macro	Recall-Macro	F1-Macro
TF-IDF + SVM	0.8796	0.7077	0.7425	0.7199
TF-IDF + Logistic Regression	0.8805	0.7100	0.7589	0.7290
DistilBERT	0.9171	0.7852	0.8136	0.7974

Ma trận nhầm lẫn



Nhận xét: DistilBERT cải thiện đáng kể lớp **neutral (63.49%)**, cao hơn khoảng **+10%** so với SVM (51%) và LR (52%).

- Nghiên cứu khẳng định DistilBERT là mô hình tối ưu nhất cho việc phân tích cảm xúc đánh giá khách sạn tiếng Việt.
- Mô hình đạt chỉ số F1-Macro vượt trội là **0.7974**.
- Kết quả phân loại chính xác và có ý nghĩa hơn so với các phương pháp truyền thống.
- Việc ứng dụng mô hình này giúp các nhà quản lý khách sạn và logistics du lịch hiểu rõ phản hồi khách hàng để từ đó tối ưu hóa chất lượng dịch vụ và phân bổ nguồn lực hiệu quả.
- Việc duy trì tập dữ liệu luôn được cập nhật là nền tảng quan trọng để đảm bảo mô hình luôn mang lại kết quả chính xác và có giá trị ứng dụng cao.

Hướng nghiên cứu tương lai

- Phát triển các mô hình lai kết hợp giữa Transformer và các phương pháp học máy truyền thống.
- Xử lý tốt hơn các sắc thái ngôn ngữ phức tạp như sự mỉa mai hoặc từ lóng đặc thù.
- Mở rộng sang phân tích cảm xúc dựa trên từng khía cạnh dịch vụ.
- Ứng dụng các kiến trúc học sâu nâng cao chuyên biệt cho tiếng Việt.

Xin cảm ƠN!