

Phân cụm các nhà sáng tạo nội dung TikTok Việt Nam

So sánh các mô hình học máy không giám sát trên dữ liệu đa chiều

1st Tấn Phát 2nd Quốc Khánh 3rd Phúc Bình

Khoa Công nghệ thông tin
Trường Đại học Công nghệ Thành phố Hồ Chí Minh (HUTECH)

Ngày 4 tháng 4 năm 2026

Nội dung trình bày

- 1 Giới thiệu và bài toán nghiên cứu
- 2 Dữ liệu và tiền xử lý
- 3 Xây dựng đặc trưng
- 4 Các mô hình phân cụm
- 5 Kết quả thực nghiệm
- 6 Đặc trưng hành vi của các cụm
- 7 Thảo luận

TikTok và influencer marketing tại Việt Nam

- TikTok đang trở thành một nền tảng quan trọng cho sáng tạo nội dung, thương mại điện tử và truyền thông số.
- Các nhãn hàng ngày càng phụ thuộc vào creator để tiếp cận khách hàng và thúc đẩy chuyển đổi.
- Tuy nhiên, việc lựa chọn creator vẫn thường dựa vào các chỉ số bề mặt như follower hoặc phân tầng quy mô.

Khoảng trống

- Những chỉ số bề mặt chưa phản ánh đầy đủ hành vi đăng tải, hiệu quả tương tác và sức lan tỏa nội dung.
- Chưa có nhiều nghiên cứu phân cụm creator theo hành vi đa chiều và liên kết với giá trị kinh doanh.

⇒ **Hướng tiếp cận:** dùng học máy không giám sát để khám phá các behavioral archetypes của TikTok creator.

Mục tiêu và câu hỏi nghiên cứu

Mục tiêu nghiên cứu

- Phân cụm các TikTok creator dựa trên đặc trưng hành vi.
- So sánh nhiều thuật toán học máy không giám sát để tìm mô hình phù hợp.
- Phân tích hậu phân cụm nhằm diễn giải giá trị kinh doanh của từng nhóm creator.

Câu hỏi nghiên cứu

- **RQ1:** Các kỹ thuật phân cụm có thể được sử dụng như thế nào để xác định các nguyên mẫu hành vi riêng biệt của creator trên TikTok?
- **RQ2:** Các cụm creator khác nhau như thế nào về giá trị kinh doanh khi xem xét các biến bên ngoài như mức giá, điểm cộng tác và danh mục nội dung?

Đóng góp của nghiên cứu

- Xây dựng bộ dữ liệu quy mô lớn từ TikTok gồm video, chỉ số hiệu suất và thông tin thương mại ở cấp creator.
- Đề xuất quy trình behavioral feature engineering từ cấp độ video lên cấp độ creator.
- So sánh bốn thuật toán phân cụm: K-Means, Hierarchical, DBSCAN và Spectral Clustering.
- Liên kết kết quả phân cụm với các biến external variables để tạo insight phục vụ brand selection.

Nguồn dữ liệu

- Dữ liệu được thu thập từ TikTok One.
- Quy mô ban đầu gồm 208,479 video của 3,000 creators trong 90 ngày gần nhất.
- Sau các bước xử lý và tổng hợp, dữ liệu phân cụm được thực hiện ở cấp độ creator.

Các nhóm biến chính

- **Định danh và thời gian:** CREATOR_ID, VIDEO_ID, CREATE_TIME
- **Tương tác:** VIEW_COUNT, LIKE_COUNT, COMMENT_COUNT, SHARE_COUNT, SAVE_COUNT
- **Thương mại:** COLLAB_SCORE, PRICE_NUM, BROADCAST_SCORE
- **Hồ sơ và kỹ thuật:** FOLLOWERS, VQSCORE, BITRATE, CATEGORY, ENGAGEMENT

Ý nghĩa của dữ liệu

Nhóm biến	Trường dữ liệu	Ý nghĩa phân tích
Định danh & thời gian	CREATOR_ID, VIDEO_ID, CREATE_TIME	Xác định đối tượng, theo dõi chuỗi đăng tải và khoảng thời gian hoạt động
Tương tác & hiệu suất	VIEW, LIKE, COMMENT, SHARE, SAVE	Đo mức độ tiếp cận, tương tác và phản ứng sâu của người xem
Thương mại	PRICE_NUM, COLLAB_SCORE, BROADCAST_SCORE	Phản ánh tiềm năng hợp tác và giá trị khai thác thương mại
Hồ sơ creator	FOLLOWERS, CATEGORY, ENGAGEMENT, VQSCORE	Mô tả quy mô, định vị nội dung và chất lượng kênh

Các bước chính

- Kiểm tra và xử lý giá trị thiếu.
- Điền thiếu bằng trung bình hoặc trung vị tùy loại biến.
- Với biến phân loại, mã hóa bằng One-Hot Encoding khi cần thiết.
- Kiểm soát giá trị cực đoan bằng Winsorization trước khi chuẩn hóa.

Mục đích

- Giảm nhiễu dữ liệu thô.
- Hạn chế ảnh hưởng của outlier lên tâm cụm.
- Đưa các biến về cùng thang đo để các mô hình phân cụm hoạt động ổn định hơn.

Chuẩn hóa dữ liệu

Kỹ thuật sử dụng

- Dữ liệu được Winsorize trước để giảm ảnh hưởng của các giá trị cực đoan.
- Sau đó áp dụng chuẩn hóa Min-Max cho các đặc trưng đầu vào.

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}}$$

Ý nghĩa

- Đảm bảo các biến có mức ảnh hưởng cân bằng hơn trong không gian phân cụm.
- Phù hợp với các thuật toán dựa trên khoảng cách như K-Means, Hierarchical và Spectral.

Xây dựng đặc trưng hành vi

Ý tưởng cốt lõi

- Dữ liệu gốc ở cấp độ video được tổng hợp lên cấp độ creator.
- Mục tiêu là biểu diễn creator bằng một hồ sơ hành vi ổn định và có khả năng so sánh.

Sau xử lý

- Bộ dữ liệu phân cụm gồm khoảng 2,845 creators đạt chuẩn.
- Sử dụng 15 đặc trưng hành vi để đưa vào mô hình.

Các đặc trưng hành vi tiêu biểu

Nhóm đặc trưng	Chỉ số	Ý nghĩa
Chiến lược đăng tải	POSTING_CONSISTENCY	Phản ánh mức độ đều đặn và kỷ luật khi đăng bài
Tần suất hoạt động	VIDEO_COUNT_3M, VIDEO_PER_WEEK	Đo cường độ sản xuất nội dung trong 3 tháng
Độ ổn định hiệu suất	VIEW_CV	Thể hiện mức biến động hiệu suất giữa các video
Giá trị nội dung	MEAN_SAVE_RATE_3M	Phản ánh mức hữu ích hoặc mức đáng lưu lại của nội dung
Sức lan tỏa	VIRAL_MAGNITUDE, MAX_VIRAL_STRENGTH	Đo khả năng tạo đột biến về lượt xem và lan truyền
Tương tác	MEDIAN_LIKE_RATE_3M, ME- DIAN_COMMENT_RATE_3M	Phản ánh khả năng kích hoạt phản ứng của người xem

Lý do

- Không gian nhiều chiều có thể gây nhiễu và làm giảm khả năng tách cụm rõ ràng.
- PCA được dùng để hỗ trợ khám phá cấu trúc dữ liệu và trực quan hóa.

Vai trò của PCA

- Giảm chiều mà vẫn giữ phần lớn phương sai.
- Hỗ trợ biểu diễn trực quan cụm trên mặt phẳng 2D.
- Không thay thế logic phân cụm, mà chủ yếu hỗ trợ diễn giải và minh họa.

Các thuật toán được so sánh

- **K-Means Clustering**
- **Hierarchical Clustering (Ward)**
- **DBSCAN**
- **Spectral Clustering**

Chỉ số đánh giá

- **Silhouette Score**: càng cao càng tốt
- **Davies-Bouldin Index**: càng thấp càng tốt
- **Calinski-Harabasz Score**: càng cao càng tốt


K-Means Clustering

Nguyên lý

- Chia dữ liệu thành K cụm dựa trên khoảng cách đến tâm cụm.
- Tối ưu bằng cách giảm tổng bình phương sai số trong cụm.

Cách chọn tham số

- Sử dụng Elbow Method để xác định số cụm phù hợp.



Biểu đồ Elbow hỗ trợ chọn số cụm K


Hierarchical Clustering

Nguyên lý

- Xây dựng cấu trúc phân cấp bằng cách liên tục gộp các cụm gần nhau.
- Nghiên cứu sử dụng liên kết Ward để tối thiểu hóa phương sai nội cụm.

Ưu điểm

- Quan sát cấu trúc dữ liệu theo nhiều mức cắt cụm.
- Trực quan hóa bằng dendrogram.



Dendrogram (Ward linkage)

Nguyên lý


- Phân cụm dựa trên mật độ, đồng thời nhận diện các điểm nhiễu.
- Không cần chỉ định trước số cụm.

Tham số chính

- ϵ : bán kính lân cận
- MinPts: số điểm tối thiểu để tạo vùng mật độ cao

Cách chọn

- Sử dụng k-NN distance plot để gợi ý giá trị ϵ .



k-distance plot để xác định ϵ


Spectral Clustering

Nguyên lý

- Dựa trên similarity graph và các đặc trưng phổ của ma trận ái lực.
- Chuyển dữ liệu sang không gian mới, nơi ranh giới cụm rõ hơn, sau đó mới phân nhóm.

Cách chọn số cụm

- Sử dụng Eigengap Heuristic để gợi ý số cụm phù hợp.



Eigengap gợi ý số cụm tối ưu

So sánh mô hình

Mô hình	Silhouette	Davies-Bouldin	Calinski-Harabasz
K-Means	0.468	0.913	2478.719
Hierarchical (Ward)	0.458	0.941	2294.165
DBSCAN	NA	NA	NA
Spectral Clustering	0.575	0.722	1152.730

Nhận xét

- Spectral Clustering cho chất lượng phân tách tốt nhất.
- K-Means và Hierarchical cho kết quả tương đối ổn định nhưng thấp hơn.
- DBSCAN không tạo được cấu trúc cụm hữu ích trong bộ dữ liệu này.

Diễn giải kết quả so sánh

Vì sao Spectral tốt hơn?

- Dữ liệu creator có tính đa chiều và có thể tồn tại ranh giới phi tuyến.
- Spectral tận dụng cấu trúc tương đồng giữa các creator thay vì chỉ dựa vào khoảng cách Euclidean thuần túy.
- Vì vậy mô hình này tách được hai nhóm creator rõ hơn so với K-Means và Hierarchical.


Vì sao DBSCAN chưa phù hợp?

- Dữ liệu không tạo thành các vùng mật độ đồng đều.
- DBSCAN rất nhạy với eps và MinPts.
- Kết quả cho thấy phần lớn điểm bị xem là nhiễu hoặc không hình thành cụm có ý nghĩa.

Trực quan hóa cụm trên không gian PCA

Trình bày cụm

- Scatter plot 2D theo PCA1 và PCA2.
- 2 cụm với 2 màu khác nhau.
- Cụm 2 chiếm đa số



Phân bố các cụm trên không gian PCA

Tổng quan hai archetypes chính

Kết quả tốt nhất cho thấy dữ liệu creator được tách thành 2 cụm chính:

- ➊ **Nhóm hoạt động tích cực và ổn định**
- ➋ **Nhóm định hướng hiệu suất và lan tỏa**

Ý nghĩa

- Đây không chỉ là sự khác biệt về quy mô follower.
- Cụm phản ánh sự khác nhau trong cách creator vận hành kênh, phân phối nội dung và tạo giá trị cho brand.

Cụm 1: Hoạt động tích cực và ổn định

Đặc điểm chính

- Tần suất hoạt động cao hơn.
- Lịch đăng bài đều đặn hơn.
- Hiệu suất hợp tác ổn định hơn.
- Phù hợp với các chiến dịch cần duy trì sự hiện diện liên tục.

Diễn giải nghiệp vụ

- Nhóm creator có tính kỷ luật cao.
- Phù hợp cho campaign always-on, seeding dài hạn.



Hành vi ổn định về tần suất và hiệu suất



Cụm 2: Định hướng hiệu suất và lan tỏa

Đặc điểm chính

- Tần suất đăng bài và độ nhất quán thấp hơn.
- Khả năng tạo video có lượt xem và độ lan tỏa cao hơn.
- Hiệu suất mang tính đột biến thay vì ổn định dài hạn.

Diễn giải nghiệp vụ

- Phù hợp chiến dịch cần bùng nổ truyền thông.
- Hiệu quả với launch campaign hoặc viral activation.



Hiệu suất cao nhưng biến động lớn

Phát hiện nổi bật

- Creator không chỉ khác nhau về quy mô mà còn khác nhau về logic vận hành nội dung.
- Có dấu hiệu tồn tại sự đánh đổi giữa **tính ổn định trong hoạt động** và **khả năng tạo hiệu suất đột biến**.
- Các cụm hành vi cung cấp góc nhìn thực tiễn hơn cho bài toán chọn creator của nhãn hàng.

Ý nghĩa

- Nhóm ổn định phù hợp với chiến dịch dài hạn.
- Nhóm viral phù hợp với chiến dịch cần độ bùng nổ trong thời gian ngắn.

- Brand có thể lựa chọn creator theo mục tiêu chiến dịch thay vì chỉ dựa vào follower.
- Có thể xây dựng chiến lược phối hợp nhiều nhóm creator:
 - Nhóm ổn định để duy trì hiện diện
 - Nhóm viral để tăng bùng nổ truyền thông

Hạn chế nghiên cứu

- Dữ liệu chỉ phản ánh 1 nhóm creato và chỉ trong cửa sổ thời gian 90 ngày.
- Chưa đi sâu vào nội dung video ở mức semantic như caption, hashtag hoặc transcript.
- Một số biến kinh doanh có thể còn thiếu hoặc chưa đủ đầy để kết luận mạnh.
- Kết quả phân cụm phụ thuộc vào pipeline xử lý đặc trưng và tiền xử lý dữ liệu.

Xin cảm ơn!