

Phân cụm các nhà sáng tạo nội dung TikTok Việt Nam: So sánh các mô hình học máy không giám sát trên dữ liệu đa chiều.

1st Tân Phát, 2nd Quốc Khánh, và 3rd Phúc Bình

Khoa Công nghệ thông tin, Trường Đại học Công nghệ Thành phố Hồ Chí Minh
Thành phố Hồ Chí Minh, Việt Nam

Email: tanphat@gmail.com, dqk2005@gmail.com, phucbinh@gmail.com,

Tóm tắt nội dung—Nghiên cứu này ứng dụng học máy không giám sát để phân cụm các nhà sáng tạo nội dung (creators) trên TikTok Việt Nam, nhằm khắc phục hạn chế của việc các nhãn hàng chỉ đánh giá đối tác dựa trên các chỉ số bề mặt (như lượng người theo dõi) mà bỏ qua các yếu tố hành vi then chốt. Dựa trên việc phân tích bộ dữ liệu quy mô lớn gồm 208.479 video từ 3.000 creators trong vòng 90 ngày, cuối cùng trích xuất 15 đặc trưng đại diện cho hành vi đăng tải và chất lượng nội dung. Qua quá trình so sánh bốn thuật toán (K-Means, Hierarchical, DBSCAN, Spectral Clustering), Spectral Clustering được xác định là mô hình tối ưu nhất với chỉ số phân tách Silhouette cao nhất đạt **0.575**, chia creators thành **nhóm hoạt động tích cực** được đặc trưng bởi tính kỷ luật cao, lịch đăng bài vô cùng nhất quán cùng hiệu suất hợp tác ổn định, phù hợp cho các chiến dịch cần duy trì sự hiện diện liên tục và **nhóm định hướng hiệu suất** tuy có tần suất hoạt động và độ nhất quán thấp hơn, nhưng lại sở hữu khả năng tạo ra các video có lượng lượt xem và sức lan tỏa vượt trội, là lựa chọn lý tưởng cho các chiến dịch marketing đột phá. Tóm lại, nghiên cứu khẳng định có sự đánh đổi giữa tần suất hoạt động và hiệu suất nội dung, qua đó cung cấp cho các thương hiệu một cơ sở dữ liệu thực tiễn để tối ưu hóa việc lựa chọn nhà sáng tạo nội dung.

I. GIỚI THIỆU

Trong những năm gần đây, TikTok đã nổi lên như một trong những nền tảng mạng xã hội có sức ảnh hưởng nhất tại Việt Nam, đóng vai trò quan trọng trong việc định hình hành vi tiêu dùng số và thương mại trực tuyến. Sự tăng trưởng thần tốc của TikTok Shop và thương mại qua livestream đã biến nền tảng này thành một hệ sinh thái tích hợp giữa sáng tạo nội dung và khả năng kiếm tiền trực tiếp. Kết quả là, tiếp thị qua người ảnh hưởng (influencer marketing) đã trở thành động lực chính thúc đẩy hiệu quả thương mại điện tử, khi các thương hiệu ngày càng dựa vào các nhà sáng tạo để tiếp cận và chuyển đổi đối tượng khách hàng.

Dù phát triển mạnh mẽ, nhưng việc đánh giá và chọn lọc creator vẫn phụ thuộc quá nhiều vào các con số bề nổi như lượng follower hay thông tin nhân khẩu học cơ bản. Cách tiếp cận này bỏ sót những yếu tố hành vi then chốt như sự đều đặn khi đăng bài, hiệu quả tương tác thực tế và sức lan tỏa của nội dung. Điều này khiến các nhãn hàng gặp khó khăn khi tìm kiếm đối tác phù hợp, gây lãng phí ngân sách marketing.

Các nghiên cứu hiện nay về tiếp thị thông qua người ảnh hưởng (influencer marketing) chủ yếu tập trung vào tác động của họ đối với hành vi người tiêu dùng, chẳng hạn như sự tin tưởng, lòng trung thành với thương hiệu và ý định mua hàng. Tuy nhiên, còn rất ít nghiên cứu phân tích một cách hệ thống các mô hình hành vi của chính những người sáng tạo nội dung bằng các phương pháp tiếp cận dựa trên dữ liệu. Cụ thể, hiếm có nghiên cứu nào áp dụng các kỹ thuật phân cụm để khám phá những hình mẫu người sáng tạo tiềm ẩn và liên kết các phân khúc hành vi này với các biến số định hướng kinh doanh.

Để giải quyết những khoảng trống nghiên cứu trên, nghiên cứu này tập trung tìm hiểu :

RQ1: Các kỹ thuật phân cụm có thể được sử dụng như thế nào để xác định các nguyên mẫu hành vi (behavioral archetypes) riêng biệt của những người sáng tạo nội dung trên TikTok?

RQ2: Các phân khúc người sáng tạo được xác định có sự khác biệt như thế nào về giá trị kinh doanh, được phản ánh qua các biến số bên ngoài như mức giá, điểm cộng tác và danh mục nội dung?

Đóng góp của nghiên cứu :

- Xây dựng một bộ dữ liệu quy mô gồm 208,479 video của 3,000 TikTok creators trong khoảng thời gian 90 ngày gần nhất, ghi lại hiệu suất và hành vi đăng bài của họ.
- Đề xuất một khung kỹ thuật đặc trưng hành vi (behavioral feature engineering framework) giúp tổng hợp dữ liệu từ cấp độ video thành cấp độ nhà sáng tạo.
- Áp dụng nhiều thuật toán phân cụm khác nhau nhằm xác định cách tiếp cận phù hợp để khám phá các nhóm hành vi của creator.
- Cung cấp các góc nhìn mang tính kinh doanh thông qua việc liên kết các nhóm creator với các đặc điểm liên quan đến hợp tác và thương mại.

II. TỔNG QUAN

Trong những năm gần đây, influencer marketing đã trở thành một lĩnh vực nghiên cứu quan trọng trong marketing và khoa học dữ liệu. Nhiều nghiên cứu đã tập trung vào việc phân loại và đánh giá influencer dựa trên các tiêu chí như số lượng người theo dõi, mức độ tương tác và ảnh hưởng đến hành vi tiêu dùng. Tuy nhiên, phần lớn các phương pháp phân loại hiện tại vẫn dựa trên các chỉ số tĩnh như follower count hoặc các phân tầng đơn giản (micro, macro, mega influencer), vốn chưa phản ánh đầy đủ sự đa dạng trong hành vi sáng tạo nội dung của creator. Các nghiên cứu gần đây đã chỉ ra rằng mức độ tương tác (engagement) thường là chỉ số phản ánh giá trị thực của influencer tốt hơn so với số lượng người theo dõi, tuy nhiên việc kết hợp nhiều chiều hành vi vẫn còn hạn chế.

Song song đó, các phương pháp phân cụm (clustering) đã được áp dụng rộng rãi trong phân tích dữ liệu mạng xã hội nhằm khám phá các cấu trúc tiềm ẩn (latent patterns) trong dữ liệu người dùng. Các thuật toán như K-Means, Hierarchical Clustering và DBSCAN được sử dụng để nhóm các đối tượng có đặc điểm tương đồng mà không cần nhãn trước. Tuy nhiên, mỗi phương pháp đều có những hạn chế riêng, chẳng hạn K-Means giả định cụm có dạng hình cầu, trong khi DBSCAN phụ thuộc mạnh vào tham số và dễ gặp khó khăn trong dữ liệu có mật độ không đồng đều. Trong bối cảnh dữ liệu mạng xã hội đa chiều và phức tạp, việc lựa chọn và áp dụng phương pháp phân cụm phù hợp vẫn là một thách thức.

Một hướng tiếp cận quan trọng trong phân tích phân cụm là phân biệt giữa các biến được sử dụng để hình thành cụm (active variables) và các biến được sử dụng để diễn giải cụm (supplementary variables). Theo Market Segmentation Analysis, việc sử dụng các biến bổ sung (external variables) để phân tích hậu phân cụm (post-hoc analysis) giúp tránh việc đưa các yếu tố kinh doanh vào quá trình hình thành cụm, từ đó giữ được tính khách quan của cấu trúc dữ liệu. Cách tiếp cận này cho phép các nhà

nghiên cứu đánh giá và diễn giải ý nghĩa của các cụm một cách độc lập, đồng thời liên kết chúng với các yếu tố bên ngoài như giá trị kinh doanh hoặc đặc điểm thị trường.

Mặc dù các nghiên cứu trước đây đã áp dụng clustering trong phân tích mạng xã hội và influencer marketing, nhưng phần lớn vẫn tập trung vào việc phân nhóm dựa trên hành vi hoặc đặc điểm nội dung, mà chưa kết hợp sâu với các biến mang tính kinh doanh. Do đó, nghiên cứu này kế thừa các phương pháp phân cụm hiện có, đồng thời mở rộng bằng cách tích hợp phân tích hậu phân cụm sử dụng các biến bên ngoài. Cách tiếp cận này không chỉ giúp xác định các nhóm hành vi (behavioral archetypes) của TikTok creators mà còn làm rõ sự khác biệt về giá trị kinh doanh giữa các nhóm, từ đó cung cấp góc nhìn có ý nghĩa thực tiễn cho hoạt động hợp tác giữa thương hiệu và creator.

III. PHƯƠNG PHÁP

A. Mô tả dữ liệu

Bộ dữ liệu nghiên cứu thu thập 208.479 video trong 90 gần nhất của 3.000 nhà sáng tạo nội dung (creators) trên nền tảng TikTok One. Bao gồm 24 đặc trưng, miêu tả sơ lược :

Nhóm biến số	Các trường dữ liệu chính	Ý nghĩa phân tích
Định danh & Thời gian	CREATOR_ID, VIDEO_ID, CREATE_TIME	Xác lập tính duy nhất của đối tượng và định vị thời điểm phát sinh dữ liệu trong chu kỳ 90 ngày
Tương tác & Cam kết	VIEW_COUNT, LIKE_COUNT, COMMENT_COUNT, SHARE_COUNT, SAVE_COUNT	Đo lường hiệu suất nội dung từ mức độ tiếp cận (Reach) đến các hành vi cam kết sâu (Deep Engagement).
Giá trị Thương mại	COLLAB_SCORE, PRICE_NUM, ANCHOR_TYPES, BROADCAST_SCORE	Đánh giá tiềm năng kinh tế, khả năng hợp tác và hiệu quả chuyển đổi thương mại của nhà sáng tạo.
Hồ sơ & Kỹ thuật	FOLLOWERS, VQSCORE, BITRATE, CATEGORY_TYPE, FOLLOWING_COUNT, ENGAGEMENT, TOTAL_LIKES, DIGG_COUNT, VIDEO_COUNT, CATEGORY	Phản ánh quy mô tầm ảnh hưởng của Creator và chất lượng kỹ thuật của tệp tin video.

B. Tiền xử lý

Dữ liệu thô từ TikTok thường chứa nhiều nhiễu, giá trị thiếu và các sai lệch do lỗi thu thập hoặc do hành vi bất thường của người dùng. Bước đầu tiên trong quy trình xử lý là xử lý giá trị thiếu, kiểm tra và điền thiếu bằng giá trị thật. Áp dụng kỹ thuật điền thiếu bằng bằng trung bình và trung vị. Đối với các biến định danh, phân loại thì dùng kỹ thuật Onehot.

C. Xây dựng đặc trưng

Quá trình xử lý dữ liệu tập trung vào việc chuyển đổi các biến thô thành các chỉ số đặc trưng (Features) nhằm xây dựng Hồ sơ hành vi kỹ thuật số toàn diện cho từng nhà sáng tạo. Các đặc trưng đưa vào phân cụm gồm 2845 dòng (2845 creator đạt chuẩn) và có 15 đặc trưng .

Nhóm đặc trưng	Chỉ số đại diện	Mục tiêu phân tích
Chiến lược đăng tải	POSTING_CONSISTENCY	Đánh giá tính kỷ luật và tính chuyên nghiệp của Creator.
Độ ổn định nội dung	VIEW_CV	Đo lường rủi ro hiệu suất và tính nhất quán của phong độ.
Giá trị nội dung	MEAN_SAVE_RATE_3M	Định lượng tính hữu dụng và giá trị lưu trữ của video.
Sức mạnh lan tỏa	VIRAL_MAGNITUDE	Nhận diện khả năng thu hút người dùng mới của nội dung.

D. Chuẩn hóa dữ liệu

Winsorization (1%–95%) được áp dụng trước khi chuẩn hóa Min-Max để ổn định tâm cụm và giảm ảnh hưởng của các giá trị cực đoan. Công thức :

$$\frac{value - min}{max - min}$$

E. Giảm chiều dữ liệu


Để xử lý “lời nguyền số chiều” và nhận diện các cấu trúc tiềm ẩn, Phân tích thành phần chính (PCA) được áp dụng. Kết quả EDA cho thấy 6 thành phần chính nắm bắt xấp xỉ 95% tổng phương sai. Điều này xác nhận rằng dù hiệu mang tính đa diện, dữ liệu vẫn có thể được chiếu xuống không gian chiều thấp hơn mà không mất mát thông tin đáng kể.

F. Mô hình phân cụm

1. K-Means Clustering

Thuật toán K-Means là một kỹ thuật học máy không giám sát dựa trên trọng tâm (centroid-based) phổ biến, nhằm phân chia tập dữ liệu thành K cụm riêng biệt dựa trên mức độ tương đồng. Quá trình này hoạt động bằng cách lặp đi lặp lại việc gán từng điểm dữ liệu vào trọng tâm gần nhất dựa trên khoảng cách Euclidean và sau đó cập nhật vị trí trọng tâm bằng giá trị trung bình của các tọa độ điểm trong cụm, với mục tiêu toán học cốt lõi là giảm thiểu Tổng bình phương sai số trong cụm (WCSS hay SSE) cho đến khi mô hình hội tụ.


Nghiên cứu áp dụng phương pháp Khuỷu tay (Elbow Method) để tìm tham số k cho K-Means. Phương pháp này biểu diễn đồ thị toán học WCSS theo từng giá trị K và tìm ra "điểm khuỷu tay", tức là điểm mà tại đó tốc độ giảm của WCSS bắt đầu chững lại đáng kể.



2. Hierarchical Clustering

Thuật toán Phân cụm phân cấp (Hierarchical Clustering) là một kỹ thuật học máy không giám sát mạnh mẽ, giúp tổ chức và phân chia dữ liệu thành một cấu trúc phân cấp đa cấp dạng cây (được gọi là biểu đồ dendrogram). Thuật toán sẽ đo lường độ tương đồng và liên tục hợp nhất các cặp cụm gần nhất lại với nhau cho đến khi tất cả các điểm dữ liệu hội tụ thành một cụm duy nhất. Việc quyết định hợp nhất các cụm được dựa trên các tiêu chí liên kết (linkage methods) như liên kết đơn (single), liên kết hoàn toàn (complete), trung bình (average), hoặc phương pháp Ward nhằm mục đích giảm thiểu sự gia tăng của phương sai nội bộ cụm.


Nghiên cứu áp dụng phương pháp Ward và hình thành biểu đồ dendrogram. Dendrogram (biểu đồ cây phân cấp) là sơ đồ dạng cây trực quan hóa quá trình phân cụm phân cấp (Hierarchical Clustering), thể hiện thứ tự hợp nhất các cụm và mức độ khoảng cách giữa chúng.



3. DBSCAN Clustering

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) là một thuật toán phân cụm học máy không giám sát hoạt động dựa trên nguyên lý mật độ không gian. Thay vì dựa vào khoảng cách đến các trọng tâm (như K-Means), thuật toán này nhóm các điểm dữ liệu nằm sát nhau ở những vùng có mật độ cao thành các cụm, đồng thời cô lập và gắn nhãn các điểm nằm rải rác ở vùng mật độ thấp là nhiễu (noise/outliers). Khác với nhiều thuật toán truyền thống, DBSCAN không yêu cầu người dùng phải xác định trước số lượng cụm. Thuật toán DBSCAN hoạt động dựa trên hai siêu tham số (hyperparameters) cơ bản để định nghĩa "mật độ" Epsilon (ϵ hay eps) và MinPts. Dựa vào ϵ và MinPts, DBSCAN sẽ phân loại mọi điểm dữ liệu trong không gian thành ba nhóm riêng biệt : Điểm lõi (Core point), Điểm biên (Border point), Điểm nhiễu (Noise point / Outlier).


Nghiên cứu dùng k-NN Distance Plot chọn eps tối ưu cho DBSCAN. Biểu đồ khoảng cách k (k-distance graph) là một kỹ thuật thích ứng được sử dụng để tinh chỉnh và ước lượng giá trị tối ưu cho các tham số cốt lõi của thuật toán DBSCAN, cụ thể là ngưỡng khoảng cách (ϵ hay epsilon) và số điểm tối thiểu (MinPts).



4. Spectral Clustering


Phân cụm phổ (Spectral Clustering) là một kỹ thuật phân cụm dữ liệu mạnh mẽ dựa trên các đặc trưng phổ của đồ thị tương đồng (similarity graph) hoặc ma trận ái lực (affinity matrix). Thuật toán này áp dụng các nguyên lý từ đại số tuyến tính và lý thuyết đồ thị để khám phá các cấu trúc ẩn bên trong dữ liệu. Ý tưởng cốt lõi của Spectral Clustering là chuyển đổi dữ liệu vào một không gian có số chiều thấp hơn, nơi ranh giới của các cụm trở nên rõ ràng và dễ nhận biết hơn, sau đó mới áp dụng một phương pháp phân cụm tiêu chuẩn vào không gian mới này.

Trong thuật toán Phân cụm phổ (Spectral Clustering), tương tự như K-Means, một trong những thách thức là mô hình yêu cầu người dùng phải xác định trước số lượng cụm (k). Để giải quyết vấn đề này nghiên cứu sẽ áp dụng Eigengap Heuristic (Khám phá khoảng trống giá trị riêng) được sử dụng như một kỹ thuật đặc lực để gợi ý số lượng cụm (K) tối ưu.



IV. KẾT QUẢ

A. So sánh mô hình



Hình ảnh trực quan hóa của 4 cụm của K-Means, Hierarchical, DBSCAN, Spectral

Model	Số cụm	Noise	Silhouette	Davies_Bouldin	Calinski_Harabasz
K-Means	2	0	0.4683715	0.9125399	2478.719
Hierarchical (Ward)	2	0	0.4576904	0.9406008	2294.165
DBSCAN	1	2490	NA	NA	NA
Spectral	2	0	0.5752894	0.7219571	1152.730

Kết quả so sánh các thuật toán phân cụm cho thấy sự khác biệt rõ rệt về khả năng nắm bắt cấu trúc dữ liệu giữa các phương pháp. Cụ thể, Spectral Clustering đạt hiệu suất tốt nhất với giá trị Silhouette cao nhất (**0.575**) và Davies–Bouldin thấp nhất (**0.722**), cho thấy các cụm được phân tách rõ ràng và có mức độ chồng lấn thấp. Điều này phản ánh khả năng của Spectral Clustering trong việc nắm bắt các mối quan hệ phi tuyến và cấu trúc phức tạp trong không gian đặc trưng, vốn không phù hợp với các giả định hình học đơn giản. Mặc dù chỉ số Calinski–Harabasz của Spectral thấp hơn so với K-Means, điều này không hàm ý hiệu suất kém mà chủ yếu do chỉ số này thiên về các cụm có dạng hình cầu, trong khi Spectral Clustering không bị ràng buộc bởi giả định này.





Ngược lại, K-Means đạt giá trị Calinski–Harabasz cao nhất (2478.7), cho thấy các cụm có độ phân tán nội bộ thấp và tách biệt tốt theo nghĩa phương sai. Tuy nhiên, giá trị Silhouette (0.468) và Davies–Bouldin (0.913) kém hơn so với Spectral, cho thấy các cụm vẫn có sự chồng lấn nhất định và chưa phản ánh rõ ràng cấu trúc thực của dữ liệu. Hierarchical Clustering (Ward) cho kết quả tương tự K-Means nhưng thấp hơn một chút trên tất cả các chỉ số, cho thấy phương pháp này không mang lại lợi thế đáng kể và cũng chịu cùng hạn chế về giả định hình dạng cụm.

Đối với DBSCAN, thuật toán này không phát hiện được cấu trúc cụm có ý nghĩa khi chỉ hình thành một cụm duy nhất và gán phần lớn quan sát (2490 điểm) là nhiễu, dẫn đến việc không thể tính toán các chỉ số đánh giá. Điều này cho thấy dữ liệu không tồn tại các vùng mật độ đủ rõ để phân tách bằng phương pháp dựa trên mật độ, và không gian đặc trưng có xu hướng phân bố liên tục thay vì hình thành các cụm đặc sít riêng biệt.

Tổng hợp các kết quả trên, Spectral Clustering được lựa chọn là mô hình phù hợp nhất cho nghiên cứu này, do đạt hiệu suất cao trên các chỉ số phản ánh trực tiếp chất lượng phân cụm (Silhouette và Davies–Bouldin), đồng thời phù hợp với bản chất phi tuyến của dữ liệu. Các phương pháp còn lại hoặc bị giới hạn bởi giả định hình dạng cụm (K-Means, Hierarchical), hoặc không phù hợp với cấu trúc dữ liệu (DBSCAN).

B. Đặc trưng hành vi của các cụm creator

Phân tích các cụm creator cho thấy sự khác biệt rõ rệt về hành vi đăng tải nội dung, quy mô và hiệu quả nội dung giữa hai nhóm.







Phân tích các cụm creator cho thấy sự khác biệt về hành vi đăng tải nội dung, quy mô và hiệu quả nội dung giữa hai nhóm. Cụ thể, Cluster SP_1 được đặc trưng bởi mức độ hoạt động cao và tính nhất quán trong đăng tải nội dung. Biểu đồ phân phối cho thấy nhóm này có giá trị posting consistency cao hơn đáng kể, với phần lớn creator duy trì lịch đăng đều đặn. Đồng thời, phân phối follower của SP_1 nghiêng về các nhóm quy mô trung bình đến lớn (đặc biệt trong khoảng 100K–500K và trên 500K), cho thấy đây là nhóm creator có nền tảng ổn định và quy mô tương đối tốt.

Ngược lại, Cluster SP_2 thể hiện mức độ hoạt động thấp hơn và tính nhất quán kém hơn, với posting consistency phân tán rộng và giá trị trung vị thấp hơn rõ rệt. Tuy nhiên, nhóm này lại có hiệu suất nội dung cao hơn. Cụ thể, mean views (3 tháng) của SP_2 cao hơn đáng kể so với SP_1 (median khoảng 105K so với 58K), đồng thời phân phối có đuôi dài hơn về phía giá trị cao, cho thấy sự tồn tại của nhiều video đạt hiệu suất vượt trội. Ngoài ra, chỉ số viral magnitude của SP_2 cũng cao hơn, phản ánh khả năng tạo ra nội dung lan truyền mạnh hơn so với SP_1.

Tổng hợp lại, hai cụm thể hiện một sự đánh đổi rõ ràng giữa tần suất hoạt động và hiệu quả nội dung. SP_1 có thể được xem là nhóm “high-activity creators”, tập trung vào việc duy trì sự hiện diện thông qua đăng tải đều đặn và ổn định. Trong khi đó, SP_2 đại diện cho nhóm “efficiency-driven creators”, với tần suất thấp hơn nhưng khả năng tạo ra nội dung có hiệu suất và độ lan truyền cao hơn. Kết quả này cho thấy hành vi creator không chỉ khác biệt về quy mô mà còn về chiến lược nội dung, từ đó cung cấp góc nhìn sâu hơn so với các phân loại truyền thống dựa trên follower.

C. Phân tích đặc điểm kinh doanh theo cụm



Kết quả phân tích cho thấy sự khác biệt rõ ràng giữa hai cụm creator không chỉ ở hành vi hoạt động mà còn ở các đặc điểm mang tính thương mại, bao gồm giá hợp tác, độ ổn định nội dung và hiệu quả hợp tác.

Trước hết, về hành vi đăng tải nội dung, như đã nêu trước đó cụm SP_1 thể hiện mức độ nhất quán cao hơn đáng kể. Giá trị posting consistency của SP_1 tập trung ở mức cao (khoảng 0.8–0.9), cho thấy nhóm này duy trì lịch đăng đều đặn và ổn định. Ngược lại, SP_2 có mức độ nhất quán thấp hơn và phân tán rộng hơn, phản ánh chiến lược nội dung kém đều đặn và mang tính linh hoạt hơn. Điều này cho thấy SP_1 hướng đến việc duy trì sự hiện diện liên tục, trong khi SP_2 không phụ thuộc vào tần suất đăng tải.

Về quy mô creator (followers), hai cụm không có sự khác biệt quá lớn về trung vị, tuy nhiên SP_2 có phân phối trải rộng hơn và xuất hiện nhiều giá trị cực đại cao hơn. Điều này cho thấy trong SP_2 tồn tại một số creator có quy mô rất lớn, trong khi SP_1 tập trung hơn ở các mức quy mô trung bình đến khá.

Xét đến giá hợp tác (price), hai cụm có mức trung vị tương đối tương đồng, cho thấy mặt bằng giá chung không khác biệt rõ rệt. Tuy nhiên, tương tự phân phối follower, SP_2 có đuôi phân phối dài hơn về phía giá cao, phản ánh khả năng đạt mức định giá

vượt trội ở một số creator. Điều này cho thấy SP_2 có giá trị thương mại cao hơn ở nhóm top performer, dù không phải là xu hướng chung của toàn cụm.

Đối với điểm hợp tác (collab score), cụm SP_1 có xu hướng ổn định và nhỉnh hơn nhẹ so với SP_2. Phân phối của SP_1 tập trung hơn quanh vùng trung vị, trong khi SP_2 có độ phân tán lớn hơn, bao gồm cả các giá trị thấp hơn. Điều này cho thấy SP_1 có hiệu suất hợp tác đồng đều và đáng tin cậy hơn, trong khi SP_2 có tính biến động cao hơn trong khả năng hợp tác.

V. KẾT LUẬN

A. Diễn giải

Kết quả phân cụm cho thấy hành vi của TikTok creators không đồng nhất mà hình thành hai nhóm với chiến lược nội dung khác biệt rõ rệt. Cụm SP_1 đại diện cho nhóm creator có mức độ hoạt động cao, duy trì lịch đăng tải ổn định và nhất quán theo thời gian. Nhóm này thường có quy mô follower trung bình đến lớn và thể hiện hiệu suất hợp tác tương đối ổn định. Ngược lại, cụm SP_2 có tần suất hoạt động thấp hơn và tính nhất quán kém hơn, nhưng lại nổi bật ở khả năng tạo ra nội dung có hiệu suất cao, với mức độ lan truyền và lượt xem vượt trội.

Sự khác biệt giữa hai cụm phản ánh một sự đánh đổi (trade-off) rõ ràng giữa tần suất hoạt động và hiệu quả nội dung. Trong khi SP_1 theo đuổi chiến lược “duy trì hiện diện” thông qua đăng tải đều đặn, SP_2 thể hiện chiến lược “tối ưu hiệu suất”, tập trung vào việc tạo ra các nội dung có khả năng lan truyền cao dù không đăng tải thường xuyên. Điều này cho thấy hành vi creator không chỉ khác biệt về quy mô mà còn về cách tiếp cận nội dung và chiến lược phát triển kênh.

B. Ý nghĩa

Từ góc độ thực tiễn, kết quả nghiên cứu mang lại ý nghĩa cho hoạt động hợp tác giữa thương hiệu và creator. Đối với các chiến dịch cần duy trì sự hiện diện liên tục và ổn định (always-on campaigns), nhóm SP_1 là lựa chọn phù hợp nhờ tính nhất quán cao và hiệu suất hợp tác ổn định. Ngược lại, đối với các chiến dịch tập trung vào hiệu ứng lan truyền hoặc tạo đột phá về lượt xem (viral campaigns), nhóm SP_2 có tiềm năng mang lại hiệu quả cao hơn nhờ khả năng tạo nội dung có sức lan tỏa mạnh.

Ngoài ra, kết quả cũng cho thấy sự tồn tại của các creator có giá trị thương mại cao nhưng không đồng đều trong cụm SP_2, phản ánh sự chênh lệch giữa hiệu suất nội dung và mức định giá trên thị trường. Điều này gợi ý rằng việc lựa chọn creator không nên chỉ dựa trên các chỉ số bề mặt như follower hoặc giá hợp tác, mà cần kết hợp với các đặc trưng hành vi và hiệu suất nội dung. Do đó, phương pháp phân cụm kết hợp với phân tích các biến bên ngoài cung cấp một cách tiếp cận hiệu quả hơn trong việc đánh giá và lựa chọn creator cho các mục tiêu marketing cụ thể.